



第十章：通用信息抽取(IE)与序列标注

哈尔滨工业大学（深圳）计算与智能研究院

Lychee Lab

目录


- ☐ 信息抽取任务谱系
- ☐ 序列标注：IE的底层逻辑与经典建模
- ☐ 从序列标注到生成式IE

目录

- ☐ 信息抽取任务谱系
- ☐ 序列标注：IE的底层逻辑与经典建模
- ☐ 从序列标注到生成式IE

什么是信息抽取?

真实世界 非结构化内容




从非结构化文本到结构化知识的桥梁

数据多样、场景复杂
多种模态相互交错



计算机系统 结构化知识



结构化、语义化与机
器可读性

什么是信息抽取?



LYCHEE




哈尔滨工业大学(深圳)
HARBIN INSTITUTE OF TECHNOLOGY, SHENZHEN

信息抽取(Information Extraction, IE)是自然语言处理领域中的一项任务, 旨在从文本中自动识别和提取特定类型的结构化信息例如实体、关系和事件等。

通常情况下, 信息抽取任务包括**命名实体识别**、**关系抽取**和**事件抽取**三个子任务:



- **命名实体识别(NER)**: 识别文本中具有特定含义的命名实体, 如人名、地名、组织机构名等;
- **关系抽取(RE)**: 在文本中识别并提取实体之间的语义关系, 如“X是Y的父亲”、“X与Y是夫妻关系”等;
- **事件抽取(EE)**: 从文本中抽取事件, 并识别出事件的组成要素, 如触发词、事件类型、参与者、时间等。



信息抽取任务广泛应用于**信息检索**、**知识图谱构建**、**自然语言问答**等领域。

命名实体识别

NER是指在给定的文本中，自动识别和分类出命名实体，即将文本中的实体识别出来，并将其分类为人名，组织机构，地名，时间、日期、货币、百分比等标准实体类型。NER可以应用于很多领域，比如信息提取、问答系统、机器翻译等，是自然语言处理中的重要任务之一。



命名实体识别主流算法

关系抽取

关系抽取(Relation Extraction)是自然语言处理领域中的一项任务，其目标是从文本中抽取出实体之间的关系。在关系抽取任务中，通常需要先进行实体识别，即识别文本中的实体，并确定它们的类别。接着，需要对这些实体进行关系抽取，找出它们之间的关系类型和关系结构。

哈尔滨工业大学坐落于哈尔滨

实体识别

关系抽取


实体识别

哈尔滨工业大学

位于

哈尔滨

三元组




关系抽取主流算法

事件抽取

事件抽取是信息抽取中的难点问题

- 事件抽取依赖实体抽取和关系抽取
- 相较于实体抽取和关系抽取，事件抽取难度更大



实体抽取

1992年10月3日, 奥巴马, 米歇尔, 三一联合基督教堂

关系抽取

夫妻关系: 奥巴马, 米歇尔

事件抽取

事件类型: 结婚事件
配偶: 奥巴马, 配偶: 米歇尔
时间: 1992年10月3日
地点: 三一联合基督教堂

1992年10月3日, 奥巴马与米歇尔在三一联合基督教堂结婚

信息抽取的挑战

□ 实体嵌套(Nested NER)

指一个实体在文本中完全包含了另一个或多个实体。

传统序列标注模型在解码时存在“标签冲突”，无法同时识别同一位置的多个语义层级。




包含多个实体级别

□ 非连续实体 (Discontinuous Entities)

构成实体的词汇在文本空间上是不连续的，但逻辑语义上是一个整体。


如何跨越“语义孤岛”进行正确配对？这要求模型不仅能识别边界，还能通过图结构或指针网络进行逻辑聚合。



🔗 Schema 依赖与零样本 (Schema Dependency & Zero-shot)

传统 IE 强依赖于预先定义的标签集(Schema)。

传统 IE 模型像是一个“偏科生”，只认识训练集里的类别，换个领域就罢工。领域迁移成本高。



目录

- ☐ 信息抽取任务谱系
- ☐ 序列标注：IE的底层逻辑与经典建模
- ☐ 从序列标注到生成式IE

序列标注协议

IE的底层数学语言

□ **标注范式：**将抽取任务转化为对序列中每个Token的分类任务

BIO: Begin, Inside, Outside (最通用)

BIOU: Begin, Inside, Last, Outside, Unit (更精细的边界描述)

□ **典型应用场景**

中文分词：将连续汉字划分为有意义的词语（如“上海自来水” → “上海/自来水”）

词性标注：为词语标注语法属性（如“苹果” → “名词”，“吃” → “动词”）

命名实体识别（NER）：识别文本中的人名、地名、机构名（如“杨幂” → “人名”，“北医三院” → “机构”）

句法分析：标注句子中词语的语法关系（如“主语-谓语” “定语-中心语”）

文本加标点：为语音识别/机器翻译输出的无标点文本添加标点（如“我去北京” → “我去北京。”）

长度为 n 的序列 $X = [X_1, X_2, X_3, \dots, X_n]$

(例：“上海自来水”)



输入

序列标注



输出

长度为 n 的标签序列 $Y = [Y_1, Y_2, Y_3, \dots, Y_n]$

(例：“0 1 0 0 1”)

1就表示在这个位置分词


这里1的位置就是输入的“海”和“水”

序列标注的实现技术

1. 基于深度学习的序列标注

流程：用神经网络（如BERT、LSTM）将每个Token转化为向量，再预测其分类标签；

典型模型：BLSTM（双向LSTM）——能同时捕捉Token的上下文信息，比如对“花园北路的北”标注实体时，BLSTM会结合前后Token的语义。



2.条件随机场 (CRF)：让序列标注更“合理”的模型

CRF是一种概率图模型，用于处理序列标注任务，核心优势是**考虑标签之间的依赖关系**（如“MA”标签通常跟随“BA”，而非直接跟随“EO”），避免独立分类导致的“标签逻辑错误”。

$$p(y|x; \theta) = \frac{1}{Z(x)} \exp\left(\sum_{i=1}^n f(y_{i-1}, y_i, x_i; \theta)\right)$$

目标：找到标签序列 y ，最大化条件概率 $p(y|x; \theta)$

$Z(x)$ ：归一化项，确保所有标签序列的概率和为1； $f(y_{i-1}, y_i, x_i; \theta)$ ：特征函数，衡量“标签转移 $y_{i-1} \rightarrow y_i$ 和Token-标签匹配 $x_i \rightarrow y_i$ 的合理性； θ ：特征函数的权重参数

损失函数：

$$Loss = \log\left(\sum_{\hat{y} \in Y_X} e^{S(X, \hat{y})}\right) - S(X, y)$$

$S(X, y)$ ：真实序列的分数（发射矩阵+转移矩阵的分数和）

序列标注的实现技术

2.条件随机场 (CRF) 的两大核心矩阵

□ 发射矩阵(Emission Matrix)—— “每个词对应什么标签” 的得分表

词	BA (地址开头)	MA (地址中间)	EA (地址结尾)	O (非地址)
花	0.95	0.03	0.01	0.01
园	0.02	0.96	0.01	0.01
北	0.01	0.97	0.01	0.01
路	0.01	0.02	0.97	0.00

□ 转移矩阵(Transition Matrix)——从一个标签转移到另一个标签的得分

前标签\后标签	BA	MA	EA	O
BA	0.1	0.8	0.0	0.1
MA	0.0	0.8	0.2	0.0
EA	0.0	0.0	0.1	0.9

序列标注的常见解码算法

模型已经给出了每个Token的标签得分（发射矩阵）和标签间的转移规则（转移矩阵），解码算法要做的就是 筛选，找到总得分最高的最优序列


1. 穷举法

遍历所有可能的标签序列，计算每个序列的总得分，选择最高分序列

□ 复杂度： D^n (n 为序列长度， D 为标签数量)

□ 短板：效率极低，仅适用于短序列

当 $n = 10, D = 5$ 时，需要遍历 $5^{10} = 9,765,625$ 种序列！



序列标注的常见解码算法

2. 维特比解码 (Viterbi Decoding)


动态规划，通过“局部最优累积”实现“全局最优”，避免重复计算。用“走一步记一步最优”的方式，快速找到全局最好的标签序列

□ 步骤

a) 初始化：先算第一步（A 列）的得分。从 start 走到 A 列的每个标签，记下每个 A 标签的“初始得分”（比如 A2 的得分比 A1、A3 高）。

b) 递推：每一步只记“到当前位置的最优路径”。走到 B 列时，对每个 B 标签（比如 B2），只算“从 A 列哪个标签来，得分最高”。

c) 回溯：从最后一步往回找最优路径。看 B 列里得分最高的标签（比如 B2），然后反向找它的前驱（A2），再找 A2 的前驱（start），就能得到完整的最优路径：
start→A2→B2。



□ 复杂度： $n * D^2$ (n 为序列长度， D 为标签数量)

□ 优势：效率远高于穷举法，且能保证找到全局最优序列，是CRF的标准解码算法

序列标注的常见解码算法

3. 束搜索 (Beam Search)


贪心策略，**每一步仅保留“得分最高的B个候选序列”**（B为束宽，如B=2、B=5），减少计算量

□ 步骤

- a) 初始化：对第一个token，选择得分最高的B个标签作为初始候选序列
- b) 递推：对每个候选序列，扩展所有可能的下一个标签，计算新序列的得分，再保留得分最高的B个序列
- c) 终止：序列结束后，从最终的B个候选序列中选择得分最高的作为最优序列

□ 复杂度： $n * D * B$ (n 为序列长度， D 为标签数量， B 为束宽)

□ 优势：效率可调（B越小效率越高，B越大精度越接近维特比），适用于长序列、大标签集场景



序列标注的常见解码算法

效率对比

解码算法	时间复杂度	核心特点	适用场景
穷举法	D^n	精度最高（遍历所有可能），效率极低	短序列、少标签（如 $n \leq 5$ 、 $D \leq 3$ ）
维特比解码	$n * D^2$	效率高，精度最优（全局最优）	大部分序列标注场景（如NER）
束搜索	$n * D * B$	效率可调，精度接近最优（ $B=5$ 时精度接近维特比）	长序列（如 $n \geq 50$ ）、大标签集

目录

- ☐ 信息抽取任务谱系
- ☐ 序列标注：IE的底层逻辑与经典建模
- ☐ 从序列标注到生成式IE

范式转移：从判别式标注到生成式抽取

判别式 (Discriminative)

Sequence Labeling

[0]→[0]→[B-LOC]→→[I-LOC]


我 爱 北京 天安门

分类问题：受限于预定义标签集

生成式 (Generative)

Seq2Seq

Input: 我
爱 北 京
天 安 门



JSON: {
"地名": ["北
京", "天安门"]
}

翻译问题：直接生成结构化文本

核心优势：统一 NER/RE/EE 形式，易于处理嵌套结构。

生成式 IE

Text-to-Structure 范式

不再是对词元 (Token) 做分类, 而是将抽取任务定义为 “将非结构化文本翻译成结构化标记语言”



打破“孤岛”效应

跨领域泛化: 凭借 LLM 内部庞大的知识储备, 模型可以理解未曾见过的实体类型。

Schema-free 的力量: 用户可以通过自然语言即时定义抽取目标 (如: “请提取文中提到的所有 ‘反派人物’ 及其 ‘超能力’ ”), 无需重新训练。