



第17章: RAG (Retrieval-Augmented Generation) 架构



学习目标与主线

学习目标与主线

01

掌握RAG检索增强生成的核心定义与组件构成，理解检索器与生成器的协同逻辑，明确RAG解决大模型幻觉、知识时效性不足的核心价值。

02

梳理从参数化知识存储到检索-生成融合的范式演变脉络，厘清传统检索问答、端到端阅读理解、封闭书大模型到RAG的技术迭代路径。

03

拆解RAG检索模块、生成模块的核心技术方法与训练策略，掌握稀疏检索、稠密检索、嵌入编码、向量索引等关键技术的落地逻辑。

04

落地RAG的典型应用模式与部署实践，识别检索准确性、多文档融合、系统效率等核心挑战，掌握针对性优化思路与可信度保障方案。



引言与全景

RAG核心定义

什么是RAG?

RAG (Retrieval-Augmented Generation, 检索增强生成) 是将**信息检索**与**文本生成**深度融合的架构, 让模型在生成时实时访问外部知识库, 从而获取准确、合规且时效性强的信息, 有效解决大模型幻觉问题。

模型不知道

覆盖模型未学习过的新知识, 打破训练数据的时间限制

→ 知识覆盖不足

模型记不准

提供权威依据, 有效减少大模型的幻觉问题, 确保答案可信

→ 幻觉问题严重

知识已过时

实时接入最新知识库, 保证信息的时效性和准确性

→ 知识滞后

外部知识依赖

生成结果不单纯依赖模型预训练记忆, 而是结合实时检索到的外部知识库信息

语义关联生成

生成器深度融合用户问题与检索内容, 进行语义层面的整合与推理

结果可追溯性

生成的每条内容都可关联到具体知识库文档来源, 提供清晰的引用依据



核心架构设计

RAG核心架构：检索器与生成器的协同

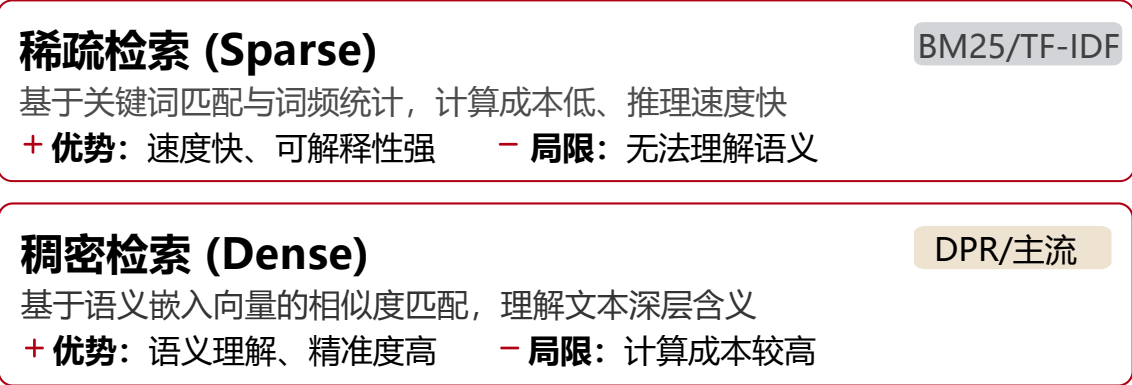


RAG四大核心环节



辅助环节：知识库索引构建 / 数据清洗与预处理 / 向量化存储

稀疏检索 vs 稠密检索



稠密检索核心流程



编解码融合生成 (Fusion-in-Decoder)

将问题与检索文档一同输入编码器进行语义融合，再由解码器生成答案

✓ 支持端到端联合训练 ✗ 架构复杂、成本高

Prompt拼接生成 (主流落地方式)

将检索片段拼接在用户问题Prompt中，整体输入给GPT/LLaMA等大模型

✓ 无需修改架构、开箱即用 ✗ 依赖Prompt工程

RAG Pipeline 系统架构全景图



LYCHEE



哈尔滨工业大学(深圳)
HARBIN INSTITUTE OF TECHNOLOGY, SHENZHEN

阶段一：索引阶段

Indexing Phase (Offline)

1 数据摄取层

从多源收集文档(PDF/DOCX/HTML), 提取文本与结构信息

数据连接器 文档解析 格式转换



2 文档处理

清洗文本、去除冗余、智能分块, 保留语义边界

文本清洗 智能分块 元数据提取



3 嵌入生成

使用Embedding模型将文本转为向量(384-1536维)

BERT Sentence-BERT E5



4 数据库存储

向量存入数据库(FAISS/Pinecone/Milvus), 构建高效索引

向量索引 HNSW IVF

核心组件层

Core Components

嵌入模型

将文本转为向量表示
编码器架构

向量数据库

存储与索引向量
相似度搜索

检索器

执行相似度搜索
混合检索策略

生成器 (LLM)

生成最终答案
GPT-4/LLaMA

后处理层

幻觉检查、引用标注、质量评估
可信度保障

数据流向与交互

- 原始文档 → 清洗分块 → 向量嵌入 → 数据库存储
- 用户查询 → 查询嵌入 → 相似度搜索 → Top-K召回
- 检索结果 → 上下文构建 → Prompt增强 → LLM生成

阶段二：推理阶段

Inference Phase (Online)

1 查询接收

用户提交问题, 系统解析意图与关键概念



2 查询嵌入

使用相同Embedding模型将查询转为向量



3 相似度搜索

在向量数据库中执行相似度搜索, 召回Top-K文档



4 结果重排序

使用Cross-Encoder对结果精排, 优化相关性



5 上下文构建

整合检索片段, 添加元数据与引用, 构建上下文



6 Prompt组装

整合系统指令、用户查询、检索上下文



7 LLM生成

增强Prompt输入LLM, 生成答案并流式输出



8 后处理与输出

幻觉检查、引用验证、质量评估后输出

核心洞察

RAG Pipeline通过"离线索引+在线推理"两阶段架构, 实现知识的动态更新与高效检索

索引
阶段

推理
阶段

核心
组件

企业级RAG应用全景与标杆案例



🗨️ 开放域知识问答

覆盖模型未学习过的新知识，打破训练数据的时间限制，提供精准的自然语言问答服务

✓ **应用场景：**智能客服、产品助手、知识库查询

🔒 企业私有文档问答

基于企业内部文档、政策、手册构建专属知识库，确保数据安全与隐私合规

✓ **应用场景：**内部培训、合规查询、流程指导

🏥 专业领域咨询

医疗、法律、金融等专业领域，基于权威文献和案例提供精准咨询建议

✓ **应用场景：**临床决策支持、法律文书生成、投资分析

📰 实时资讯生成

实时接入最新知识库，保证信息的时效性和准确性，辅助生成科技报告、新闻摘要

✓ **应用场景：**新闻摘要、市场分析、舆情监测

★ 标杆企业案例与量化效果

🏢 Siemens

知识管理平台

↑ 响应时间 ↓ 40%

🏢 Morgan Stanley

财富管理RAG系统

↑ 顾问效率 ↑ 35%

🛒 Amazon

电商推荐引擎

↑ 转化率 ↑ 25%

💓 IBM Watson

医疗诊断辅助

↑ 诊断准确率 96.4%

🚚 DoorDash

司机支持聊天机器人

↑ 问题解决率 ↑ 60%

🔄 LinkedIn

内部支持助手

↑ 解决时间 ↓ 28.6%



训练范式与实战

技术范式演进：从参数化知识到检索增强



LYCHEE



哈尔滨工业大学(深圳)
HARBIN INSTITUTE OF TECHNOLOGY, SHENZHEN

1 检索+模板

基于关键词和规则模板，逻辑简单但语义理解能力差

➖ 局限性：无法理解语义

2 端到端阅读

能从给定文本中抽取答案，但知识覆盖受上下文长度限制

➖ 局限性：上下文窗口限制

3 封闭书大模型

无需检索直接生成，但存在知识滞后和幻觉问题

➖ 局限性：幻觉+知识滞后

4 RAG检索增强

融合检索与生成，实时调用外部知识，大幅提升准确性与可信度

✔ 优势：准确+时效+可信

↔ RAG vs 传统LLM：本质区别

旧 传统大模型

- ✗ 依赖预训练记忆，知识固定
- ✗ 训练数据截止后无法更新
- ✗ 可能生成看似合理但错误的内容
- ✗ 无法追溯答案来源

新 RAG增强架构

- ✔ 实时检索外部知识库，动态更新
- ✔ 知识库可随时更新，无需重新训练
- ✔ 基于检索内容生成，事实准确
- ✔ 每条答案可追溯至原文档

“**核心洞察**：RAG不是替代大模型，而是为其提供“外部大脑”，让模型从“背诵知识”转变为“查阅资料+推理生成”，实现知识动态化、答案可追溯、结果可验证。



能力扩展与评估

核心应用模式与部署实践

核心应用模式

知识型问答系统

覆盖开放域与封闭域，提供精准的自然语言问答服务。

知识增强对话系统

赋能智能客服与机器人，实现更专业、准确的多轮对话。

专业内容生成

辅助生成科技报告、法律文书及医疗咨询等专业文案。

系统部署流程

01. 知识库预处理

清洗文档、智能分块，高效处理长文档上下文问题。

02. 向量索引构建

将文档编码为Embedding向量，存入数据库并建立高效索引。


03. 服务化部署

封装检索与生成模块为API服务，提供高并发推理能力。


RAG性能提升：关键数据与基准测试




📊 准确率提升数据



🛡️ 幻觉率降低数据




🏆 RAG系统性能对比



测试基于92个真实文档问答场景

🚀 企业部署效果



💡 **关键洞察：** RAG不仅提升准确率，更在**医疗、金融、客服**等高要求场景下实现接近人类专家水平的性能表现。



挑战、前沿与总结

RAG核心技术挑战与优化路径

检索准确性问题

"检索错则生成错"，若检索到无关或错误文档，生成结果将直接出错

优化策略

- ✓ 采用**稀疏+稠密混合检索策略**，兼顾关键词匹配与语义理解
- ✓ 加入**重排序模块**（Cross-Encoder），提升Top-K文档相关性
- ✓ 使用**查询扩展与改写技术**，增强检索覆盖率

多文档融合难题

难以有效整合多源信息，易遗漏关键内容或产生逻辑矛盾

优化策略

- ✓ 通过**Prompt工程**引导模型整合信息，明确多文档关系
- ✓ 对检索结果进行**摘要预处理**，压缩冗余信息
- ✓ 采用**层次化检索**（如RAPTOR树结构），提供不同粒度信息

系统效率瓶颈

串行流程导致推理速度慢，且向量索引对硬件资源要求较高

优化策略

- ✓ 利用**向量数据库分布式部署**，提升并发处理能力
- ✓ 采用**索引压缩与量化技术**（如HNSW、IVF），降低存储成本
- ✓ 实施**语义缓存策略**，减少重复查询开销

知识时效性与更新

知识库需持续更新以避免内容过时，但更新过程复杂且成本高

优化策略

- ✓ 构建**自动化知识库更新流水线**，实现增量更新
- ✓ 采用**实时索引动态更新机制**，保持知识新鲜度
- ✓ 建立**版本控制与回滚机制**，确保更新安全性

可信度与可追溯性保障

模型仍可能基于检索结果进行错误推理，且自动生成引用的精度有待提升。建立"**生成+校验**"闭环机制，明确标注信息来源，有效过滤幻觉与错误内容，提升结果可信度。采用**多源验证与置信度评分**，确保答案可靠性。

RAG未来发展方向与技术前沿



Agentic RAG

从基础RAG向Agentic RAG发展，实现自主决策与多智能体协作

- ✓ 自主规划与推理能力
- ✓ 多智能体协同工作
- ✓ 工具调用与API集成



GraphRAG

增强关系推理能力，基于知识图谱构建更强大的检索系统

- ✓ 实体关系深度理解
- ✓ 多跳推理能力
- ✓ 结构化知识融合



多模态RAG

融合文本、图像、音频等多种模态，实现跨模态检索与生成

- ✓ 图文混合检索
- ✓ 视频内容理解
- ✓ 跨模态语义对齐



端到端联合训练

检索器与生成器共享训练流程，联合优化参数，实现协同工作

- 📍 让检索器精准召回对生成最有帮助的文档，生成器利用文档产出最优答案



RAG + Fine-tuning融合

结合RAG的外部知识检索能力与Fine-tuning的领域适配性

- 📍 在特定领域场景下，先Fine-tuning提升基础能力，再通过RAG引入实时知识



RAG：大模型外部知识支撑的主流架构

RAG作为大模型外部知识支撑场景下的**主流可靠架构**，将持续推动AI应用向更高准确性、更强可信度的方向发展。从基础RAG到Agentic RAG、GraphRAG、多模态RAG，技术演进将不断拓展RAG的应用边界，实现从简单信息检索到复杂知识推理的跨越。

01

RAG 核心是融合信息检索与文本生成技术，重构大模型内容生成逻辑

02

精准解决大模型幻觉、知识滞后、知识覆盖不足三大核心痛点

03

成为大模型外部知识支撑场景下的主流可靠应用架构