





# 第20章： AI for Science

# 用 AI 加速科研闭环

AI for Science 不是用 AI 代替科研人员写论文，而是把**机器学习 / 深度学习**当作“加速器”，嵌入到科研与工程研发的每个关键步骤里。

- 从文献与历史数据中提炼规律并提出可检验的假设
- 预测在不同条件下材料或分子的性质与表现
- 辅助设计更少但信息量更高的实验与对照组
- 加速数值模拟与参数扫描





## 1. 数据规模与数据类型的爆发式增长



高通量实验让我们一次能得到成百上千组配方与结果，显微图像与各类谱图把微观结构与化学信息数字化，天文巡天与基因组测序则带来了远超人工分析能力的大规模观测数据。

## 2. 算力门槛的明显下降



GPU 和分布式训练让更大更复杂的模型可以在可接受的时间内训练与推理，把原来“算不起”的任务变成了“算得动”。

## 3. 模型能力更通用



深度学习从单一任务的特征工程转向可迁移的表征学习，大模型进一步把文本、图像、序列等信息统一起来，能够跨任务复用知识并减少对大量标注的依赖。

# 预测型任务：从结构与条件到性质与结果的映射

## 任务核心

“给定输入，预测结果”，把科研中的大量问题转化为可学习的映射关系。

- **分子结构与表示**（例如 SMILES、分子图、3D 构象）
- **材料配方与工艺条件**（组分比例、温度、时间、溶剂、pH 等）
- **实验表征数据**（显微图像、拉曼/红外/质谱等谱图、时间序列信号）

- **关键性质参数**（电导率、离子迁移率、带隙/能带相关指标、机械强度）
- **功能表现与活性**（催化活性、药物活性、选择性）
- **稳定性与寿命**（热稳定、化学稳定、循环稳定）
- **工程结果类指标**（反应产率、纯度、缺陷率）

把“昂贵的实验或仿真”尽可能替换为“便宜的预测”，用于快速筛选候选、缩小搜索空间，并在给定条件约束下做参数探索与敏感性分析，从而**显著减少试错次数并提升研发效率**。

输入 Inputs

输出 Outputs

价值 Value

用可靠的性质与结果预测来减少试错次数，**快速筛选**并锁定最值得进一步实验验证的候选与条件。

# 生成与设计型任务：主动提出候选

## 新分子结构与片段组合

在满足基本化学规则的前提下提出新的骨架或取代基搭配，并同时兼顾溶解度、活性、选择性、ADMET 等性质约束。它通常与性质预测模型或打分函数配合，用“生成—评估—再生成”的循环，把候选快速推向更接近先导化合物的区域。

## 新材料结构、晶体构型或配方组


提出可能带来目标性质提升的结构单元、掺杂策略或组分比例，并把工艺条件作为重要输入一起考虑。它的典型用法是先大范围提出候选，再用快速模拟或代理模型筛到少量最有希望的结构，显著减少昂贵的 DFT 或实验合成次数。

## 蛋白或核酸序列

在保持功能位点或结构骨架的同时，对序列进行可控改写，从而提升稳定性、表达量、亲和力或特异性。实践中常把“可折叠性/可表达性/免疫原性风险”等约束一起加入筛选，让生成的序列更接近可实验验证的真实候选。

## 实验条件与工艺参数

把目标指标（例如产率、纯度、信噪比、缺陷率）转化为可优化的条件搜索问题，并给出下一批最值得做的参数组合与对照实验。它往往结合主动学习或贝叶斯优化，把每次实验当作一次“信息获取”，用更少实验更快锁定最佳窗口。





# 生成与设计型任务：主动提出候选

01


## 多目标约束与现实可行性

与预测型不同，生成与设计型任务往往要在同一时间满足多个目标与约束，例如性能更高、毒性更低、成本更低，同时还要保证可合成、可制造、可规模化，并处于安全与合规范围内。

02

## 从枚举试错到闭环优化

让模型先在巨大组合空间里提出少量更有希望的候选，并明确它们为什么值得尝试。随后再用性质预测、仿真或小批量实验做快速筛选与淘汰，把验证结果回流给模型继续迭代，从而更快、更便宜地逼近最优解，并把研发从大量低效试错转向少量高信息量的闭环优化。。



# 因果与机理型任务：从相关性走向可验证的“为什么”



LYCHEE



哈尔滨工业大学(深圳)  
HARBIN INSTITUTE OF TECHNOLOGY, SHENZHEN

把模型预测转化为可解释机制与可干预实验设计

## 科学问题

很多科学数据里同时**变化的因素太多**，比如配方、温度、溶剂、样品批次、仪器漂移等都会一起影响结果，普通预测模型可能抓住了表面相关，但不能保证改变某个变量就会产生相同方向的效果

## 方法

会结合领域知识与实验设计思想，例如用因果图或结构化假设把变量关系写清楚，用对照实验、消融与干预数据来验证因果方向，用反事实推断回答“如果只改变 A，B 会怎样”，并用可解释的中间表征把机制线索落到可观察证据上。

## 价值

- 把文献与数据中的机制线索结构化，帮助提出更像“可验证科学假设”的解释；
- 自动生成更严谨的验证方案，例如必须补哪些对照、该控制哪些混杂因素、下一步实验最能区分哪两种机制假设，从而**让研究更接近因果结论而不是停留在相关性**。


## 核心

识别真正起作用的关键因素，区分“原因”与“伴随现象”，从而支持可靠的干预与控制。

# 科学数据与互联网数据的关键差异


## 科学数据

科学数据通常**规模更小而且获取成本更高**，数据里常带有仪器漂移、批次差异等结构化噪声，不同实验条件或不同实验室之间很容易出现**分布偏移**，同时标签往往来自测量或仿真，可能包含系统误差并受条件强烈影响。



## 互联网数据

互联网数据通常**规模更大且更容易收集**，噪声更多是随机或可被大规模平均掉的，训练与应用场景的分布相对更稳定一些，并且标签多来自人工标注或用户行为，虽然也会有偏差但通常**不直接受物理实验条件约束**。





# 生成与设计型任务：主动提出候选

## 分子与材料数据

通常以多种层次出现，既可以是 1D 的 SMILES 表达，也可以是更贴近化学结构的分子图表示，还可以进一步到 3D 构象、晶体结构与晶格参数，用来描述原子连接关系、空间几何与周期性结构信息。

## 序列数据


主要来自生命科学，常见的是蛋白质氨基酸序列与 DNA/RNA 碱基序列，它们往往需要结合功能位点、保守区与结构折叠信息来理解。

## 蛋白或核酸序列

在保持功能位点或结构骨架的同时，对序列进行可控改写，从而提升稳定性、表达量、亲和力或特异性。实践中常把“可折叠性/可表达性/免疫原性风险”等约束一起加入筛选，让生成的序列更接近可实验验证的真实候选。


## 实验条件与工艺参数

把目标指标（例如产率、纯度、信噪比、缺陷率）转化为可优化的条件搜索问题，并给出下一批最值得做的参数组合与对照实验。它往往结合主动学习或贝叶斯优化，把每次实验当作一次“信息获取”，用更少实验更快锁定最佳窗口。



## 核心逻辑

大模型的价值在于多模态对齐：把这些异构数据映射到可共享的表示空间。




## 单位与实验条件统一

把单位与实验条件统一到可复现的标准，并且把关键条件显式写进数据字段而不是留在备注里，因为**温度、溶剂、pH、离子强度、湿度、扫描速率**等往往不是“背景”，而是会直接改变反应路径与测量结果的决定性变量。如果这些条件缺失或不一致，同一个“标签”在不同样本里其实代表了不同物理意义，模型很容易学到伪规律。

## 面向真实外推

例如按**分子骨架、材料体系、样品批次、实验时间或实验室来源**切分，而不是简单随机打散，因为随机切分常把高度相似的样本同时放进训练集与测试集，导致指标虚高；只有在更严格的切分下仍然表现稳定，模型才更可能在真实研发场景里可靠工作。



保留重复试验并记录  
不确定性来源

包括**重复测量的方差、批次差异、仪器漂移与基线校正方式**，同时在建模时把不确定性当作输出的一部分或至少在评估时体现出来，这样才能避免模型把偶然噪声当作可泛化的信号，也能让后续筛选更知道哪些预测“值得信”。

01

## 序列 – Transformer

序列的关键难点是**长距离依赖和上下文选择**。注意力机制能让模型在任一步都直接参考全序列并自动挑重点，同时训练更易并行扩展到大数据大模型。直观地说，它更像“在整段内容里随时检索相关片段”，而不是只能按顺序死记硬背。

02

## 图结构 – GNN

图的本质是节点之间的关系而不是固定顺序。GNN 通过“消息传递”让节点从邻居聚合信息，逐层把局部连接模式汇成更高层表示，天然**适合分子、社交网络、知识图谱**这类任务。换句话说，图任务往往是“邻居怎么影响我”，GNN 就把这种影响当作默认建模方式。

03

## 图像 – CNN / ViT

图像既有强局部规律也需要全局理解。CNN 用卷积捕捉可重复的局部纹理与边缘，数据效率高；ViT 把图像块当序列用注意力建模全局关系，更擅长捕捉长距离组合与整体布局。

04

## 多模态 – 融合模型

不同模态各自表达不同信息，关键在**“对齐与互补”**。通常先用各自合适的编码器提特征，再用跨注意力或融合层把文本、图像、结构、谱图等信息对齐并联合推理，才能真正把多源信息用起来。

**依据输入数据的结构特征选择具有相应归纳偏置的模型架构**

# 生成：直接提出候选结构

VAE

## VAE 变分自编码器

VAE 会把离散的结构（例如分子图、晶体结构描述符）编码到一个连续的潜空间中，在这个空间里相近的点通常对应相似的结构与性质，因此可以做平滑插值与局部编辑。对设计而言，它最大的价值在于把“离散组合爆炸”的结构空间，转化成“连续可优化”的表征空间，研究者可以在潜空间里进行定向移动或采样，再解码回可解释的结构候选。

特征

## Diffusion Model 扩散模型

扩散模型通过“从噪声到结构”的逐步去噪过程学习复杂分布，因而在生成精细结构、保持局部合理性方面往往更强。对材料与分子而言，它适合生成具有多尺度细节的对象，例如在满足局部化学合理性、空间几何约束或晶体对称性约束的同时，仍能覆盖多样的全局构型。

生成

任务

## Autoregressive Model 自回归模型

自回归方法把结构表示成序列（如 SMILES、SELFIES、晶体的离散化序列或构型 token），并按条件逐步生成下一个符号，因此非常适合做“给定条件下的控制生成”。它的优势在于生成过程可被清晰地条件化与约束化，例如限定元素集合、官能团、骨架片段或某些结构片段必须出现，从而把领域知识以“生成规则”的形式注入模型。



# 实验闭环与自动化实验室：把‘预测’变成‘行动’

## 核心特点

把“提出实验—执行实验—读出结果—更新决策”做成一个可重复运行的闭环系统，而不是把建模与实验割裂开来。

用主动学习、贝叶斯优化或强化学习等策略，在极其庞大的实验设计空间里优先挑选“**信息增益最高**”或“**期望改进最大**”的实验批次，从而把有限预算花在最值得做的地方。

不仅追求找到更优候选，还会显式权衡探索与利用，并把安全边界、可合成性、设备可达范围等约束一起纳入决策，使得输出的候选既有科学价值也可实际执行。

把配方制备、反应或培养、加样与滴定、过程控制以及多模态表征等环节用机器人与自动化平台串成标准化流程，并通过**高通量并行**显著提升单位时间的实验产出。

通过固定的操作顺序、参数闭环控制与一致的实验条件来降低人为差异与批次漂移，从而**提高数据一致性**，让模型学习到的规律更稳定、更可迁移。

把“实验从仪器到可训练数据”的**全过程工程化**：自动采集原始文件与日志，统一格式与单位，完成校准、去噪、异常检测与质量控制，并把样品 ID、批次、工艺参数、仪器设置与读出结果严格绑定以保证可追溯。

让数据在时间维度上可持续累积、在不同设备与不同批次之间可比较、在复现实验时可还原，从而为闭环迭代提供可靠且不断增长的训练语料。

智能选点

自动执行

数据管线

在更低试错成本下实现**更快、更稳**的迭代优化与发现

# 实验闭环与自动化实验室：把‘预测’变成‘行动’

## 1. 决策与设计

模型基于历史数据与不确定性估计提出下一批要做的实验条件或配方，常见方法包括**主动学习与贝叶斯优化**，并且会把约束（安全、可合成、工艺边界、并行能力）一起编码进候选生成。

## 2. 自动执行

调度系统把候选分配给具体设备，机器人完成称量加样、混合、温控、反应时间控制以及自动滴定或培养流程，并在节点处触发表征设备（如光谱、电化学、显微、质谱等）获取读出。

## 工作流程

## 3. 数据回流

系统自动抓取仪器文件与日志，进行**格式统一、校准、异常检测、重复一致性检查**，并把条件参数、批次、样品 ID 与表征结果绑定成可追溯记录入库。

## 4. 模型更新与再迭代

用新数据更新性质预测器与不确定性模型，**重新评估目标函数与约束表现**，再生成下一轮候选，从而在少量实验次数内快速逼近最优区域并持续提高样本效率。

**在约束条件下以更少实验实现更快收敛与更高样本效率的发现与优化。**